

二阶锥面约束优化问题及其求解方法

目录

1 原优化问题	3
2 松弛后优化问题	3
3 基于方向的线性割平面方法	4
3.1 Cauchy-Schwarz 不等式	4
3.2 带收缩因子的方向割	5
3.3 收缩因子 r 的几何分析	5
3.3.1 二维情况分析	5
3.3.2 三维情况分析	6
3.4 层次化方向细分与收缩因子策略	7
3.4.1 第一层：象限等分线方向 ($r = r_{min}$)	7
3.4.2 第二层： $1/2$ 象限细分 (r 适度增大)	7
3.4.3 第 k 层：一般化策略	7
3.5 自适应添加割的算法	7
3.6 方法特点与复杂度分析	9
4 差凸规划迭代方法	10
4.1 差凸分解	10
4.1.1 基本范数形式的差凸分解	10
4.1.2 平方形式的差凸分解	10
4.1.3 旋转二阶锥的差凸分解	11
4.2 线性化与迭代	12
4.2.1 基本范数形式的线性化	12
4.2.2 平方形式的线性化	12
4.2.3 旋转二阶锥形式的线性化	13
4.3 算法流程	14
4.4 投影步骤（可选）	16

1 原优化问题

考虑如下带有二阶锥面约束的优化问题：

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & \|x_i\|_2 = t_i, \quad i = 1, 2, \dots, m \end{aligned} \tag{1}$$

其中：

- $x = (x_1^T, x_2^T, \dots, x_m^T, t_1, t_2, \dots, t_m)^T \in \mathbb{R}^n$ 为决策变量
- $c \in \mathbb{R}^n$ 为目标函数系数向量
- $A \in \mathbb{R}^{p \times n}$, $b \in \mathbb{R}^p$ 定义线性等式约束
- $x_i \in \mathbb{R}^{n_i}$ 为第 i 个锥变量分量
- $t_i \in \mathbb{R}$ 为第 i 个锥的高度变量
- $\|x_i\|_2 = t_i$ 定义二阶锥的面约束 (boundary constraint)

注记 1. 二阶锥面约束 $\|x_i\|_2 = t_i$ 要求点 (x_i, t_i) 必须位于二阶锥的表面，而不是内部。这与标准的二阶锥约束 $\|x_i\|_2 \leq t_i$ 不同。

定义 1 (二阶锥面). 对于给定的 $x_i \in \mathbb{R}^{n_i}$ 和 $t_i \in \mathbb{R}$, 二阶锥面定义为：

$$\mathcal{S}^{n_i} = \{(x_i, t_i) \in \mathbb{R}^{n_i+1} : \|x_i\|_2 = t_i, t_i \geq 0\}$$

问题 (1) 是非凸的，因为二阶锥面约束是非凸约束。直接求解该问题在计算上具有挑战性。

2 松弛后优化问题

为了求解原问题，我们首先考虑其凸松弛形式。将二阶锥面约束 $\|x_i\|_2 = t_i$ 松弛为二阶锥约束 $\|x_i\|_2 \leq t_i$, 得到：

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & \|x_i\|_2 \leq t_i, \quad i = 1, 2, \dots, m \end{aligned} \tag{2}$$

定理 1. 问题 (2) 是一个标准的二阶锥规划 (Second-Order Cone Programming, SOCP) 问题，是凸优化问题，可以通过内点法等高效算法求解。

定义 2 (二阶锥). 对于给定的 $x_i \in \mathbb{R}^{n_i}$ 和 $t_i \in \mathbb{R}$, 二阶锥 (*Lorentz cone*) 定义为:

$$\mathcal{K}^{n_i} = \{(x_i, t_i) \in \mathbb{R}^{n_i+1} : \|x_i\|_2 \leq t_i\}$$

注记 2. 松弛问题 (2) 的可行域包含原问题 (1) 的可行域, 即原问题的可行域是松弛问题可行域的子集。因此, 松弛问题的最优值提供了原问题最优值的下界。

设 x_{relax}^* 为松弛问题 (2) 的最优解。如果 x_{relax}^* 满足所有的面约束 $\|x_i^*\|_2 = t_i^*$, 则 x_{relax}^* 也是原问题的最优解。否则, 需要进一步处理。

3 基于方向的线性割平面方法

当松弛问题的解不满足面约束 $\|x_i\|_2 = t_i$ 时, 通常有 $\|x_i\|_2 < t_i$ (点在锥内部)。本节介绍一种基于方向的纯线性割平面方法, 通过在不同方向上添加线性割约束逐步收紧可行域。

3.1 Cauchy-Schwarz 不等式

Cauchy-Schwarz 不等式是线性代数中的基本不等式, 在二阶锥规划中具有重要应用。对于任意向量 $u, v \in \mathbb{R}^n$, 有:

$$|u^T v| \leq \|u\|_2 \|v\|_2 \quad (3)$$

等号成立当且仅当 u 和 v 线性相关 (即存在实数 λ 使得 $u = \lambda v$ 或 $v = \lambda u$)。

不等式 (3) 可以等价地写作 $(u^T v)^2 \leq (u^T u)(v^T v)$ 。在二阶锥约束 $\|x_i\|_2 \leq t_i$ 中, Cauchy-Schwarz 不等式提供了方向投影的上界。

引理 1 (方向投影的上界). 设 (x_i, t_i) 满足二阶锥约束 $\|x_i\|_2 \leq t_i$ 。对于任意方向向量 $d \in \mathbb{R}^{n_i}$, 由 Cauchy-Schwarz 不等式可得:

$$\frac{d^T x_i}{\|d\|_2} \leq \|x_i\|_2 \leq t_i \quad (4)$$

证明. 由 Cauchy-Schwarz 不等式: $|d^T x_i| \leq \|d\|_2 \|x_i\|_2$, 因此 $d^T x_i \leq \|d\|_2 \|x_i\|_2$ (注意 $d^T x_i$ 可能为负, 但上界仍成立)。除以 $\|d\|_2 > 0$ (若 $d = 0$, 不等式平凡成立), 得 $\frac{d^T x_i}{\|d\|_2} \leq \|x_i\|_2$ 。结合锥约束 $\|x_i\|_2 \leq t_i$, 即得结论。 \square

该引理表明, 对于锥内部的点, 沿任意方向 d 的投影均不超过 t_i 。这为构造方向性线性割约束提供了基础。

3.2 带收缩因子的方向割

为了更有效地收紧可行域，我们引入收缩因子 $r \in [0, 1]$ ，构造如下线性割：

$$\frac{d^T x_i}{\|d\|_2} \geq r \cdot t_i \quad (5)$$

定理 2 (收缩割的有效性). 当 $r = 1$ 时，约束 (5) 要求 $\frac{d^T x_i}{\|d\|_2} \geq t_i$ 。由于 Cauchy-Schwarz 不等式给出 $\frac{d^T x_i}{\|d\|_2} \leq \|x_i\|_2 \leq t_i$ ，当 $r = 1$ 时，仅有沿方向 d 的锥面点 $x_i = \frac{t_i}{\|d\|_2} d$ 满足约束（此时等号成立）。当 $r < 1$ 时，约束放松，保留更多的锥面和锥内部点。

注记 3. 约束 (5) 的几何意义：

- 在超球面 $x_i^T x_i = t_i^2$ 上，该约束定义了一个半空间的下界
- 当 $r = 1$ 时，约束最紧：只有在方向 d 上的锥面点满足 $(d^T x_i = t_i \|d\|)$
- 当 $r < 1$ 时，约束放松：保留方向 d 附近一个范围内的锥面点
- r 越小，保留的角度范围越大； r 越大（接近 1），保留的范围越小
- 通过选择不同的 r 值，可以控制割的紧度

3.3 收缩因子 r 的几何分析

我们分析收缩因子 r 与实际被割掉区域的关系。

3.3.1 二维情况分析

考虑二维情况 $x_i = (x_1, x_2)^T \in \mathbb{R}^2$ ，方向 $d = (d_1, d_2)^T$ 。约束 (5) 变为：

$$\frac{d_1 x_1 + d_2 x_2}{\sqrt{d_1^2 + d_2^2}} \geq r \cdot t \quad (6)$$

锥面上的点：设 $x_1^2 + x_2^2 = t^2$ （锥面），参数化为 $x_1 = t \cos \theta$, $x_2 = t \sin \theta$ 。

设方向 d 对应角度 α （即 $d_1 = \|d\| \cos \alpha$, $d_2 = \|d\| \sin \alpha$ ），则：

$$\frac{d^T x}{\|d\|_2} = t(\cos \alpha \cos \theta + \sin \alpha \sin \theta) = t \cos(\theta - \alpha) \quad (7)$$

约束 (5) 要求：

$$\cos(\theta - \alpha) \geq r \quad (8)$$

定理 3 (二维锥面上的可行角度). 对于二维锥面上的点，约束 (5) 保留的角度范围为：

$$\theta \in [\alpha - \arccos(r), \alpha + \arccos(r)] \quad (9)$$

当 $r = 1$ 时，仅保留方向 d 本身 ($\arccos(1) = 0$ ，退化为一点)；当 $r \rightarrow 0$ 时，保留以方向 d 为中心的 180° 范围 ($\arccos(0) = \pi/2$ ，即半圆)；当 $r = -1$ 时，保留整个圆周 ($\arccos(-1) = \pi$)。

证明. 由 $\cos(\theta - \alpha) \geq r$, 得 $|\theta - \alpha| \leq \arccos(r)$ 。因此可行角度为 $\theta \in [\alpha - \arccos(r), \alpha + \arccos(r)]$ 。
□

几何解释 (二维):

- $r = 1$: 约束 $d^T x \geq t\|d\|$, 仅保留方向 d 本身 ($\arccos(1) = 0^\circ$)
- $r = 1/\sqrt{2} \approx 0.707$: $\arccos(r) = 45^\circ$, 保留 90° 角度范围
- $r = 1/2$: $\arccos(r) = 60^\circ$, 保留 120° 角度范围
- $r = 0$: $\arccos(r) = 90^\circ$, 保留 180° 角度范围 (以方向 d 为中心的半圆)

3.3.2 三维情况分析

考虑三维情况 $x_i = (x_1, x_2, x_3)^T \in \mathbb{R}^3$, 方向 $d \in \mathbb{R}^3$ 。锥面为球面 $x_1^2 + x_2^2 + x_3^2 = t^2$ 。

约束 (5) 在球面上定义了一个球冠 (spherical cap)。设 γ 为 x_i 与 d 之间的夹角, 则:

$$\cos \gamma = \frac{d^T x_i}{\|d\|_2 \|x_i\|_2} = \frac{d^T x_i}{\|d\|_2 t} \quad (10)$$

约束变为: $\cos \gamma \geq r$, 即:

$$\gamma \leq \arccos(r) \quad (11)$$

定理 4 (三维球冠体积比). 在三维球面上, 约束 (5) 保留的球冠占球面面积的比例为:

$$\text{比例} = \frac{1-r}{2} \quad (12)$$

证明. 球冠的面积比例为 $\frac{1}{2}(1 - \cos \theta_0)$, 其中 $\theta_0 = \arccos(r)$ 是球冠的半顶角。约束 $\cos \gamma \geq r$ 即 $\gamma \leq \arccos(r)$ 保留了与方向 d 夹角不超过 θ_0 的球冠, 其面积比例为 $\frac{1-r}{2}$ 。
□

几何解释 (三维):

- $r = 1$: 保留 0% 的球面 (仅方向 d 本身, $\arccos(1) = 0^\circ$)
- $r = 0.5$: 保留 25% 的球面 (一个球冠)
- $r = 0$: 保留 50% 的球面 (以方向 d 为中心的半球)
- $r = -1$: 保留 100% 的球面 (整个球面)

注记 4. 从上述分析可见:

- 较大的 r 值 (接近 1) 产生更紧的割, 仅保留方向 d 附近的锥面点
- 较小的 r 值产生较松的割, 保留更多方向的锥面点
- 实际应用中, r 的选择需要平衡收敛速度和可行性保证
- 层次化策略: 先用较小的 r 值覆盖较大范围, 再逐步增大 r 值精确逼近锥面

3.4 层次化方向细分与收缩因子策略

为了系统地逼近锥面，我们采用层次化方向细分策略，并在每层使用适当的收缩因子 r 。

3.4.1 第一层：象限等分线方向 ($r = r_{min}$)

在第一层，我们使用象限的等分线方向，收缩因子 $r = r_{min}$ (较小值，如 0.5 或 0.6)，以覆盖较大的角度范围。对于二维情况：

$$\begin{aligned} d^{(1)} &= (1, 1)^T : \frac{x_{i1} + x_{i2}}{\sqrt{2}} \geq r_{min} \cdot t_i \\ d^{(2)} &= (-1, 1)^T : \frac{-x_{i1} + x_{i2}}{\sqrt{2}} \geq r_{min} \cdot t_i \\ d^{(3)} &= (-1, -1)^T : \frac{-x_{i1} - x_{i2}}{\sqrt{2}} \geq r_{min} \cdot t_i \\ d^{(4)} &= (1, -1)^T : \frac{x_{i1} - x_{i2}}{\sqrt{2}} \geq r_{min} \cdot t_i \end{aligned} \quad (13)$$

3.4.2 第二层：1/2 象限细分 (r 适度增大)

在第二层，我们在相邻方向之间插入新方向，并使用适度增大的收缩因子。对于第一象限：

$$\begin{aligned} d^{(1,1)} &= (2, 1)^T : \frac{2x_{i1} + x_{i2}}{\sqrt{5}} \geq r_2 \cdot t_i \\ d^{(1,2)} &= (1, 2)^T : \frac{x_{i1} + 2x_{i2}}{\sqrt{5}} \geq r_2 \cdot t_i \end{aligned} \quad (14)$$

其中 $r_2 > r_{min}$ ，例如当 $r_{min} = 0.5$ 时，可取 $r_2 \approx 0.7$ 。

3.4.3 第 k 层：一般化策略

定义 3 (层次化收缩因子). 在第 k 层，我们使用收缩因子：

$$r_k = r_{min} + \frac{k-1}{K_{max}-1} \cdot (1 - r_{min}) \quad (15)$$

其中 K_{max} 是最大层数， $r_{min} \in [0.5, 0.7]$ 是初始收缩因子。这使得收缩因子从 r_{min} 逐渐递增到 1。

3.5 自适应添加割的算法

基于上述分析，我们设计一个自适应添加割平面的算法。

Algorithm 1 自适应方向割平面方法

- 1: 输入: 问题 (1) 的数据; 容差 $\epsilon > 0$; 最大层数 L_{max} ; $r_{min} = 0.5$
- 2: 输出: 近似最优解 x^*
- 3: 初始化: $k \leftarrow 0$, $\ell \leftarrow 1$, 线性割集合 $\mathcal{L} \leftarrow \emptyset$
- 4: 生成第一层方向集 \mathcal{D}_1 (所有象限的等分线)
- 5: 计算第一层收缩因子: $r_1 = r_{min}$
- 6: **for** 每个锥 i 和每个方向 $d \in \mathcal{D}_1$ **do**
- 7: 添加割 $\frac{d^T x_i}{\|d\|_2} \geq r_1 \cdot t_i$ 到 \mathcal{L}
- 8: **end for**
- 9: **repeat**
- 10: 求解带割的松弛问题:

$$\begin{aligned} x^{k+1} = \arg \min \quad & c^T x \\ \text{s.t.} \quad & Ax = b \\ & \|x_i\|_2 \leq t_i, \quad i = 1, \dots, m \\ & \text{所有 } \mathcal{L} \text{ 中的线性割} \end{aligned}$$

- 11: 计算残差: $\Delta_i^{k+1} = t_i^{k+1} - \|x_i^{k+1}\|_2, \forall i$
- 12: **if** $\max_i \Delta_i^{k+1} < \epsilon$ **then**
- 13: **break** // 收敛到面约束
- 14: **end if**
- 15: // 自适应添加新割
- 16: **for** 每个锥 $i = 1, \dots, m$ **do**
- 17: **if** $\Delta_i^{k+1} > \epsilon$ **then**
- 18: 识别当前点 x_i^{k+1} 所在方向: $\hat{d}_i = x_i^{k+1} / \|x_i^{k+1}\|_2$
- 19: 在方向 \hat{d}_i 附近查找已有割的违反程度
- 20: 计算收缩因子: $r = r_{min} + \frac{\ell-1}{L_{max}-1} \cdot (1 - r_{min})$
- 21: 在 \hat{d}_i 附近生成新方向 d^{new} (通过 Farey 序列或角度插值)
- 22: 添加新割: $\frac{(d^{new})^T x_i}{\|d^{new}\|_2} \geq r \cdot t_i$ 到 \mathcal{L}
- 23: **end if**
- 24: **end for**
- 25: **if** 连续多次迭代无改进且 $\ell < L_{max}$ **then**
- 26: $\ell \leftarrow \ell + 1$
- 27: 生成第 ℓ 层全局方向集 \mathcal{D}_ℓ
- 28: 计算对应的收缩因子: $r_\ell = r_{min} + \frac{\ell-1}{L_{max}-1} \cdot (1 - r_{min})$
- 29: **for** 每个锥 i 和每个方向 $d \in \mathcal{D}_\ell$ **do**
- 30: 添加割 $\frac{d^T x_i}{\|d\|_2} \geq r_\ell \cdot t_i$ 到 \mathcal{L}
- 31: **end for**
- 32: **end if**
- 33: $k \leftarrow k + 1$
- 34: **until** $k \geq K_{max}$

注记 5. 算法的关键特点:

- **自适应性:** 根据当前解的位置动态添加割
- **层次化:** 从粗到细逐步细分方向
- **收缩因子递增:** 随层数增加逐步增大 r (从 r_{min} 到 1), 使割从较松逐步变紧, 精确逼近锥面
- **局部与全局结合:** 既在违反点附近添加局部割, 也定期添加全局方向割

3.6 方法特点与复杂度分析

注记 6. 基于方向的线性割平面方法具有以下特点:

- **纯线性:** 所有割都是形如 $d^T x \geq r \cdot t$ 的线性约束
- **可调节紧度:** 通过收缩因子 r 控制割的紧度
- **几何直观:** 每个割对应一个方向上的投影约束
- **自适应细分:** 根据求解进展决定是否进入下一层
- **低维高效:** 对于二维和三维问题特别有效

注记 7. 复杂度分析:

- **方向数量:** 第 ℓ 层有 $O(2^{n_i \cdot \ell})$ 个方向
- **约束总数:** 经过 L 层后, 每个锥有 $O(2^{n_i \cdot L})$ 个线性割
- **逼近精度:** 由收缩因子和方向细分共同决定
- **计算成本:** 每次迭代求解一个 $SOC\!P$, 规模随割数线性增长

定理 5 (收敛性). 对于给定的容差 $\epsilon > 0$, 存在有限层数 L 和适当的收缩因子序列 $\{r_k\}$, 使得算法 1 返回的解满足:

$$\max_i |\|x_i\|_2 - t_i| \leq \epsilon$$

证明. 通过层次化细分, 方向集覆盖所有可能的方向。对于每个方向, 收缩因子的递减保证了逐步逼近锥面。由于每次添加割都收紧可行域, 且 $SOC\!P$ 求解保证全局最优, 因此算法最终收敛。 \square

4 差凸规划迭代方法

差凸规划 (Difference of Convex Programming, DC Programming) 是处理非凸优化问题的有效方法。我们可以将二阶锥面约束改写为差凸形式，并利用松弛问题的解作为初始值进行迭代。

4.1 差凸分解

二阶锥面约束具有多种等价形式，可以从不同角度进行差凸分解。本节介绍三种常用的分解方法。

4.1.1 基本范数形式的差凸分解

二阶锥面约束 $\|x_i\|_2 = t_i$ 可以等价地表示为：

$$\|x_i\|_2 \leq t_i \quad \text{且} \quad t_i \leq \|x_i\|_2 \quad (16)$$

注意到：

- 约束 $\|x_i\|_2 \leq t_i$ 是凸的
- 约束 $t_i \leq \|x_i\|_2$ 等价于 $-\|x_i\|_2 \leq -t_i$ ，可以改写为 $t_i - \|x_i\|_2 \leq 0$

函数 $g_i(x_i, t_i) = t_i - \|x_i\|_2$ 是凹函数（两个凸函数的差）。因此约束 $g_i(x_i, t_i) \leq 0$ 是非凸的。

4.1.2 平方形式的差凸分解

二阶锥面约束 $\|x_i\|_2 = t_i$ 两边平方后等价于：

$$\|x_i\|_2^2 = t_i^2 \quad \Leftrightarrow \quad x_i^T x_i = t_i^2 \quad (17)$$

这可以改写为：

$$x_i^T x_i \leq t_i^2 \quad \text{且} \quad t_i^2 \leq x_i^T x_i \quad (18)$$

注意到：

- 约束 $x_i^T x_i \leq t_i^2$ 等价于 $\|(x_i, t_i)\|_2 \leq \sqrt{2}t_i$ （旋转二阶锥，见下一小节），但更常用的等价形式是：

$$\begin{bmatrix} 2t_i \\ x_i \end{bmatrix} \in \mathcal{Q}^{n_i+1} \quad \text{当且仅当} \quad x_i^T x_i \leq t_i^2 \quad (19)$$

实际上，这等价于 $\|x_i\|_2 \leq t_i$ （在 $t_i \geq 0$ 时）

- 约束 $t_i^2 \leq x_i^T x_i$ 等价于 $x_i^T x_i - t_i^2 \geq 0$

函数 $h_i(x_i, t_i) = x_i^T x_i - t_i^2$ 是凸函数减凸函数 ($x_i^T x_i$ 是凸的, t_i^2 也是凸的)。约束 $h_i(x_i, t_i) \geq 0$ 等价于 $-h_i(x_i, t_i) \leq 0$, 即:

$$t_i^2 - x_i^T x_i \leq 0 \quad (20)$$

函数 $\tilde{g}_i(x_i, t_i) = t_i^2 - x_i^T x_i$ 是凸函数 (t_i^2 是凸的) 减去凸函数 ($x_i^T x_i$ 是凸的), 因此是 DC 函数 (凸函数的差)。

注记 8. 平方形式的优点:

- 线性化后得到二次约束, 可能更精确
- 在某些应用中 (如椭球约束), 平方形式更自然
- 避免了范数计算中的不可微问题 (当 $\|x_i\|_2 = 0$ 时)

4.1.3 旋转二阶锥的差凸分解

旋转二阶锥 (Rotated Second-Order Cone, RSOC) 定义为:

$$\mathcal{Q}_r^{n+2} = \{(x, y, z) \in \mathbb{R}^n \times \mathbb{R} \times \mathbb{R} : \|x\|_2^2 \leq yz, y \geq 0, z \geq 0\} \quad (21)$$

对于二阶锥面约束 $\|x_i\|_2 = t_i$, 我们可以引入辅助变量 s_i , 将其改写为旋转锥形式:

$$\|x_i\|_2^2 = t_i^2 \Leftrightarrow \|x_i\|_2^2 \leq t_i \cdot t_i \text{ 且 } t_i \cdot t_i \leq \|x_i\|_2^2 \quad (22)$$

更一般地, 引入辅助变量 $s_i = t_i$, 约束变为:

$$\begin{aligned} x_i^T x_i &\leq t_i s_i, \quad t_i \geq 0, \quad s_i \geq 0 \\ t_i s_i &\leq x_i^T x_i \\ s_i &= t_i \end{aligned} \quad (23)$$

注意到:

- 约束 $(x_i, t_i, s_i) \in \mathcal{Q}_r^{n+2}$ 即 $x_i^T x_i \leq t_i s_i, t_i \geq 0, s_i \geq 0$ 是凸的
- 约束 $t_i s_i \leq x_i^T x_i$ 等价于 $x_i^T x_i - t_i s_i \geq 0$
- 约束 $s_i = t_i$ 是线性的

函数 $\phi_i(x_i, t_i, s_i) = x_i^T x_i - t_i s_i$ 中:

- $x_i^T x_i$ 是 x_i 的凸函数
- $t_i s_i$ 是凹函数 (双线性项在适当约束下)

约束 $\phi_i(x_i, t_i, s_i) \geq 0$ 等价于 $-\phi_i(x_i, t_i, s_i) \leq 0$:

$$t_i s_i - x_i^T x_i \leq 0 \quad (24)$$

注记 9. 旋转二阶锥形式的优点:

- 某些 SOCP 求解器对旋转锥有专门优化
- 双线性项 $t_i s_i$ 的线性化可能比 t_i^2 更简单
- 在某些应用中 (如几何规划), 旋转锥形式更自然
- 当 $s_i = t_i$ 时, 退化为标准二阶锥面约束

4.2 线性化与迭代

在差凸规划框架下, 我们对凹部分进行线性化。以下分别给出三种分解方法的线性化形式。

4.2.1 基本范数形式的线性化

在当前迭代点 (x_i^k, t_i^k) 处对凹函数 $-\|x_i\|_2$ 进行线性化:

$$-\|x_i\|_2 \approx -\|x_i^k\|_2 - \frac{(x_i^k)^T}{\|x_i^k\|_2} (x_i - x_i^k) \quad (25)$$

因此, 约束 $t_i - \|x_i\|_2 \leq 0$ 线性化为:

$$t_i + \frac{(x_i^k)^T}{\|x_i^k\|_2} (x_i - x_i^k) \leq \|x_i^k\|_2 \quad (26)$$

整理后:

$$\frac{(x_i^k)^T}{\|x_i^k\|_2} x_i - t_i \leq \frac{(x_i^k)^T x_i^k}{\|x_i^k\|_2} - t_i^k \quad (27)$$

4.2.2 平方形式的线性化

对于平方形式的约束 $t_i^2 - x_i^T x_i \leq 0$, 在点 (x_i^k, t_i^k) 处线性化:

对 t_i^2 在 t_i^k 处线性化:

$$t_i^2 \approx (t_i^k)^2 + 2t_i^k(t_i - t_i^k) \quad (28)$$

对 $x_i^T x_i$ 在 x_i^k 处线性化:

$$x_i^T x_i \approx (x_i^k)^T x_i^k + 2(x_i^k)^T (x_i - x_i^k) \quad (29)$$

因此, 约束 $t_i^2 - x_i^T x_i \leq 0$ 线性化为:

$$(t_i^k)^2 + 2t_i^k(t_i - t_i^k) - (x_i^k)^T x_i^k - 2(x_i^k)^T (x_i - x_i^k) \leq 0 \quad (30)$$

简化后:

$$2t_i^k t_i - 2(x_i^k)^T x_i \leq (x_i^k)^T x_i^k - (t_i^k)^2 \quad (31)$$

4.2.3 旋转二阶锥形式的线性化

对于旋转锥形式的约束 $t_i s_i - x_i^T x_i \leq 0$ (其中 $s_i = t_i$), 在点 $(x_i^k, t_i^k, s_i^k = t_i^k)$ 处线性化:

双线性项 $t_i s_i$ 在 (t_i^k, s_i^k) 处线性化:

$$t_i s_i \approx t_i^k s_i^k + s_i^k(t_i - t_i^k) + t_i^k(s_i - s_i^k) \quad (32)$$

由于 $s_i = t_i$, 上式变为:

$$t_i^2 \approx (t_i^k)^2 + 2t_i^k(t_i - t_i^k) \quad (33)$$

对 $x_i^T x_i$ 的线性化同平方形式。因此, 约束 $t_i s_i - x_i^T x_i \leq 0$ 线性化为:

$$(t_i^k)^2 + 2t_i^k(t_i - t_i^k) - (x_i^k)^T x_i^k - 2(x_i^k)^T (x_i - x_i^k) \leq 0 \quad (34)$$

这与平方形式的线性化一致 (当 $s_i = t_i$ 时)。

注记 10. 三种线性化形式的比较:

- **基本范数形式:** 需要计算 $\|x_i^k\|_2$ 和梯度 $(x_i^k)^T / \|x_i^k\|_2$, 当 $\|x_i^k\|_2 \approx 0$ 时需要特殊处理
- **平方形式:** 避免了范数计算, 但引入了二次项的线性化
- **旋转锥形式:** 当 $s_i = t_i$ 时与平方形式等价, 但提供了更灵活的建模方式

实际应用中, 基本范数形式最常用; 平方形式在 x_i 接近零点时更稳定。

4.3 算法流程

Algorithm 2 基于差凸规划的迭代方法（基本范数形式）

1: **输入:** 问题 (1) 的数据 c, A, b ; 容差 $\epsilon > 0$; 最大迭代次数 K_{max}

2: **输出:** 可行解 x^*

3: 求解松弛问题 (2), 得到初始解 x^0

4: 初始化: $k \leftarrow 0$

5: **repeat**

6: 求解线性化子问题:

$$x^{k+1} = \arg \min c^T x$$

$$\text{s.t. } Ax = b$$

$$\|x_i\|_2 \leq t_i, \quad i = 1, \dots, m$$

$$\frac{(x_i^k)^T}{\|x_i^k\|_2} x_i - t_i \leq \frac{(x_i^k)^T x_i^k}{\|x_i^k\|_2} - t_i^k, \quad i = 1, \dots, m$$

7: 计算残差: $r^{k+1} = \max_i |\|x_i^{k+1}\|_2 - t_i^{k+1}|$

8: **if** $r^{k+1} < \epsilon$ **then**

9: **break** // 收敛到可行解

10: **end if**

11: $k \leftarrow k + 1$

12: **until** $k \geq K_{max}$

13: **return** x^k

Algorithm 3 基于差凸规划的迭代方法（平方形式）

1: 输入：问题 (1) 的数据 c, A, b ; 容差 $\epsilon > 0$; 最大迭代次数 K_{max}

2: 输出：可行解 x^*

3: 求解松弛问题 (2), 得到初始解 x^0

4: 初始化: $k \leftarrow 0$

5: **repeat**

6: 求解线性化子问题:

$$x^{k+1} = \arg \min c^T x$$

$$\text{s.t. } Ax = b$$

$$\|x_i\|_2 \leq t_i, \quad i = 1, \dots, m$$

$$2t_i^k t_i - 2(x_i^k)^T x_i \leq (x_i^k)^T x_i^k - (t_i^k)^2, \quad i = 1, \dots, m$$

7: 计算残差: $r^{k+1} = \max_i |\|x_i^{k+1}\|_2 - t_i^{k+1}|$

8: **if** $r^{k+1} < \epsilon$ **then**

9: **break** // 收敛到可行解

10: **end if**

11: $k \leftarrow k + 1$

12: **until** $k \geq K_{max}$

13: **return** x^k

定理 6 (收敛性). 如果算法 2 或算法 3 产生的序列 $\{x^k\}$ 有界, 则其任意收敛子列的极限点是问题 (1) 的稳定点。

注记 11. 差凸规划方法的优点包括:

- 每次迭代求解的子问题仍然是凸优化问题 (SOCP)
- 利用松弛问题的解作为初始值, 通常能快速收敛
- 目标函数值单调递减 (当可行时)
- 对于某些问题, 能够收敛到二阶锥面约束的可行解

注记 12. 三种 DC 分解方法的选择建议:

- **基本范数形式:** 最常用, 几何意义清晰, 适用于大多数问题
- **平方形式:** 当初始点接近原点时更稳定 (避免 $\|x_i\|_2 = 0$ 的奇异性)
- **旋转锥形式:** 当使用支持旋转锥的求解器时, 可能有计算优势; 也可用于更一般的双线性约束

实践中, 可以根据问题特点选择最合适的方法, 或尝试多种方法取最优解。

4.4 投影步骤（可选）

如果迭代后仍未精确满足面约束，可以添加投影步骤：

对每个锥 i ，将 (x_i^k, t_i^k) 投影到二阶锥面：

$$\begin{cases} \bar{x}_i = x_i^k \\ \bar{t}_i = \|x_i^k\|_2 \end{cases} \quad \text{或} \quad \begin{cases} \bar{x}_i = \frac{t_i^k}{\|x_i^k\|_2} x_i^k \\ \bar{t}_i = t_i^k \end{cases} \quad (35)$$

根据目标函数值选择更优的投影点。

5 总结

本文研究了带有二阶锥面约束的优化问题及其求解方法：

- **原问题：** 带有线性目标函数、线性等式约束和二阶锥面约束的非凸优化问题
- **凸松弛：** 将面约束松弛为锥约束，得到可高效求解的 SOCP 问题
- **基于方向的纯线性割平面方法：** 利用方向投影添加纯线性约束，通过层次化细分和收缩因子逐步逼近锥面
- **差凸规划方法：** 利用 DC 分解和迭代线性化，从松弛解出发求得面约束的可行解

两种方法各有优劣：

- 纯线性割平面方法易于理解和实现，保持问题的凸性，但对高维问题效率较低
- 差凸规划方法收敛快，但求解的是非凸问题，可能收敛到局部解

在实际应用中，可以结合两种方法的优点，设计混合算法以获得更好的性能。